

Predicción de la concentración diaria de
NO₂ en Madrid mediante

Machine Learning

Ana Belén Balmaseda, Daniel García y Victoria Visentini

Objetivo


T1

Problema:
Contaminación atmosférica en Madrid.

Objetivo:
Estimar la concentración diaria de NO_2
utilizando datos históricos,
meteorológicos y de tráfico.

Aplicación:
Apoyar el análisis y seguimiento de la
calidad del aire.

DATASET



Datos utilizados

Fuentes

- Calidad del aire
- Meteorología
- Tráfico

Periodo

- 2019 – 2024

Dataset final

- 51.001 observaciones



ANÁLISIS EXPLORATORIO

Principales hallazgos

- Variabilidad entre estaciones.
- Estacionalidad del NO_2 .
- Relación con variables meteorológicas.
- Identificación de valores atípicos y datos faltantes.



PREPROCESADO

Por qué feature engineering y el split

- Dataset original: 16 columnas (NO2, meteo, tráfico, distancias).
- La contaminación tiene memoria (el NO2 de hoy se parece al de ayer) y depende mucho de la estación de medición.
- Split cronológico train_fe/test_fe (corte en el percentil 80 de las fechas, ~80/20), no aleatorio.
- ⚠ Necesario para los lags: si mezclas fechas al azar, un lag puede "ver" el futuro.

```
fecha_corte = fechas_unicas[int(len(fechas_unicas) * 0.8)]  
train_fe = df[df['fecha'] < fecha_corte].copy()  
test_fe = df[df['fecha'] >= fecha_corte].copy()
```

PREPROCESADO

Features temporales

- Mes y día del año en seno/coseno, para que diciembre y enero queden cerca numéricamente.
- Flag de fin de semana y estación del año

```
X['mes_sin'] = np.sin(2 * np.pi * X['fecha'].dt.month / 12)  
X['mes_cos'] = np.cos(2 * np.pi * X['fecha'].dt.month / 12)  
X['finde'] = X['fecha'].dt.dayofweek.isin([5, 6]).astype(int)
```


PREPROCESADO

Memoria del NO2: lags y medias móviles

- Lag de 1 día y de 7 días, y medias móviles de 3 y 7 días, por estación.
- Bloque con más peso predictivo: la contaminación no cambia de golpe.
- ⚠ Los primeros días de cada estación se quedan sin lag (pendiente decidir imputar o eliminar).

```
grupo = X.groupby('estacion')['no2']  
X['no2_lag1'] = grupo.shift(1)  
X['no2_roll_mean_7'] = grupo.shift(1).rolling(7).mean().reset_index(level=0, drop=True)
```

PREPROCESADO

Meteo y estación de medición

- viento_vel/precipitacion: imputación con mediana + flag de si el dato faltaba (71% y 54% missing).
- Estación de medición: target encoding con el NO2 medio histórico de cada una.
- Ambos estadísticos se calculan solo con train.

```
X[f'{col}_missing'] = X[col].isna().astype(int)
X[col] = X[col].fillna(self.medianas_[col])

self.medias_estacion_ = X.groupby('estacion')['no2'].mean()
```



PREPROCESADO

Pipeline y resultado

- Los 4 pasos encadenados en un Pipeline de sklearn: fit_transform en train, transform en test.
- Así ningún estadístico se calcula con datos de test.
- Resultado: de 16 columnas originales a 28, guardadas en parquet listas para modelar.

```
pipeline_fe = Pipeline([
    ('temporales', FeaturesTemporales()),
    ('lags_no2', FeaturesLagNO2()),
    ('imputador_meteo', ImputadorMeteo()),
    ('target_encoder', TargetEncoderEstacion()),
])
train_fe_procesado = pipeline_fe.fit_transform(train_fe)
test_fe_procesado = pipeline_fe.transform(test_fe)
```

ESTRATEGIA MODELADO DE




Metodología



- Baseline ($\text{NO}_2_{\text{lag1}}$)
- Validación cruzada temporal
- Comparación de modelos
- Optimización de hiperparámetros
- Evaluación final sobre test

COMPARACIÓN DE MODELOS


T1



Resultados de validación



Modelo seleccionado:
Ridge (alpha = 1000)

Modelo	MAE
Baseline	795
Ridge	695
HistGradientBoosting	706



Métrica	Valor
MAE	6.959
RMSE	8.999
R^2	654

Evaluación final




RESULTADOS SOBRE TEST


Mejora frente al
baseline: 3.56%

INTERPRETACIÓN DEL MODELO

T1



Variables
más
relevantes



- NO₂ del día anterior
- Velocidad del viento
- Humedad
- Estación del año
- Fin de semana

Conclusiones

- Se desarrolló un pipeline reproducible.
- Ridge obtuvo el mejor rendimiento.
- El modelo superó al baseline.
- Puede servir como base para futuros trabajos.

Trabajo futuro

- Nuevas variables.
- Datos en tiempo real.
- Modelos más avanzados.